

大数据处理课程期末项目

短视频主题偏好分析与推荐策略优化研究

基于 Tsinghua ShortVideo Dataset 的实证分析

课程名称	大数据处理
学院	国家网络安全学院
指导教师	汪润
小组成员	梁珂、方家烨、李俊婕、刘翔
项目主题	短视频主题偏好分析、关联规则挖掘与推荐策略优化

2026 年 5 月 13 日

摘要

短视频推荐系统面对的是高频曝光、弱反馈密集、内容主题多样的行为数据。课程项目围绕“如何从用户观看和互动行为中识别主题偏好，并将可解释的群体规律用于推荐排序”展开，基于 Tsinghua ShortVideo Dataset 的抽样交互数据，构建了从数据清洗、主题行为统计、用户主题画像、关联规则挖掘到推荐策略评估的完整流程。实验将原始多标签曝光记录聚合为用户-视频级交互，构造观看比例、有效观看、互动反馈和负反馈等特征，并按用户时间顺序划分训练集与测试集，避免偏好构建和规则挖掘阶段使用测试行为。推荐实验设置了两个可比较方案：baseline 只使用用户历史主题偏好和视频热门度，rule-enhanced 在此基础上引入分群主题成功率、关联规则质量、相似主题迁移、标签匹配和负反馈风险。实验结果显示，rule-enhanced 在 HitRate@10、Precision@10、Recall@10 和 ThemeMatch@10 上均超过 baseline，说明主题级规则和群体反馈可以为个体历史偏好提供有效补充。项目同时给出 Python 本地流水线、Spark 主题统计与 FP-Growth 实现、Hive 离线数仓 SQL，以及可复现的结果表和可视化图表。

关键词：短视频推荐；主题偏好；用户画像；关联规则；推荐评估；Spark；Hive

核心结果。清洗后数据包含 129,483 条交互、6,654 名用户、31,496 个视频和 36 个一级主题。训练集挖掘出 7,658 条主题/标签/用户属性到行为的关联规则。与 baseline 相比，rule-enhanced 的 HitRate@10 从 0.023013 提升至 0.026107，Recall@10 从 0.008712 提升至 0.009914，ThemeMatch@10 从 0.412038 提升至 0.423806。

目录

1	研究背景与问题定义	4
2	数据来源与实验边界	4
2.1	数据来源	4
2.2	字段结构	5
2.3	实验边界	5
3	数据清洗与特征构建	6
3.1	用户-视频级交互表	6
3.2	交互偏好得分	6
3.3	训练测试切分	6
4	方法设计	7
4.1	整体流程	7
4.2	主题行为统计	7
4.3	关联规则挖掘	8
4.4	推荐方案	8
5	实验结果与分析	9
5.1	主题行为差异	9
5.2	关联规则结果	10
5.3	推荐效果	11
5.4	用户分群偏好	12
6	大数据工具实现与可复现性	13
6.1	Python 本地流水线	13
6.2	Spark 与 Hive 实现	13
6.3	仓库产物	14

7 讨论与改进方向	14
8 小组分工	14
9 结论	15

1 研究背景与问题定义

短视频平台的内容分发高度依赖推荐系统。与传统长视频或新闻推荐相比，短视频交互具有曝光频率高、单次观看时间短、反馈信号稀疏但类型丰富的特点。用户可能没有显式评分，却会通过观看时长、是否完整观看、点赞、收藏、评论、转发和负反馈等行为留下偏好线索。对于课程项目而言，这类数据适合用来训练完整的大数据处理能力：需要从原始行为表中清洗字段、构建中间表、聚合主题统计、挖掘行为规则，并将结果放回推荐排序中验证效果。

本文关注的核心问题不是“哪一个视频最热门”，而是“不同主题如何影响用户行为，以及这些主题规律能否转化为推荐增益”。为回答这一问题，项目将视频一级主题作为主要分析对象，把用户属性、视频标签和行为反馈纳入同一个统计框架。主题行为统计用于观察不同内容类型的观看深度和互动差异，用户主题偏好画像用于描述个体兴趣，关联规则用于刻画标签、主题、用户分组和行为之间的可解释关系，推荐实验则检验这些规律是否能改善 Top-10 离线推荐结果。

课程报告的贡献体现在三个层面。数据层面，项目完成了从原始抽样表到用户-视频级交互表的清洗和去重，处理了布尔字段、观看比例、年龄分组、价格分组和主题映射等问题。方法层面，项目设计了可解释的偏好得分和 rule-enhanced 重排序方案，将主题偏好、热门度、分群反馈、规则质量、标签匹配和负反馈风险统一到推荐分数中。工程层面，项目同时保留本地 Python 流水线、Spark 实现和 Hive SQL，使报告结论可以追溯到代码和输出文件。

2 数据来源与实验边界

2.1 数据来源

实验使用 Tsinghua ShortVideo Dataset 的小规模抽样数据。完整数据集包含大规模视频文件、多模态特征和行为记录，体量不适合在普通本地环境完整下载和上传。因此，本项目将原始抽样数据保留在本地 `data_raw/shortvideo_tiny/`，在仓库中只提交清洗后的轻量表、统计结果、推荐结果、图表、脚本和报告。推荐实验主要使用 `interaction_sampled.csv` 与 `categories_cn_en.csv`，前者提供用户曝光、观看、互动、视频属性和用户属性，后者提供类别 ID 与中英文主题名称的映射。

这种数据取舍符合课程项目的目标。完整视频文件更适合多模态内容理解任务，而本文的重点是大数据处理流程和基于主题行为的推荐策略验证。抽样数据能够支持清洗、聚合、规则挖掘、推荐评估和可视化展示，也能保证实验在本地机器上可重复运行。

2.2 字段结构

交互表同时包含用户、视频、时间、行为和内容标签等字段。表 1 汇总了本文使用的核心字段。

表 1: 实验使用的核心字段

字段类别	字段名	用途
用户标识	user_id	构建用户画像，按用户划分训练集和测试集
视频标识	pid	作为推荐候选和命中评估对象
时间字段	exposed_time	保留用户行为顺序，避免随机切分造成泄露
观看行为	watch_time, duration	计算观看比例和有效观看
互动行为	cvm_like, comment, collect, forward	表示点赞、评论、收藏和转发等正向反馈
负反馈	hate	推荐排序中的风险惩罚信号
主题与标签	root_id, category_id, tag_name	构建主题统计、规则事务和标签匹配特征
用户属性	gender, age, fre_city_level	支持性别、年龄段和城市等级分组分析

2.3 实验边界

抽样实验不能直接等同于工业推荐系统评测。样本只覆盖一段有限时间窗口，候选视频也来自训练集中出现过的视频，因此本文不评价新视频冷启动和长期兴趣漂移。离线指标的绝对值会受到样本规模、测试集正反馈稀疏性和候选集合限制影响。报告更关注同一数据切分下两个推荐方案的相对差异，即 rule-enhanced 是否能稳定超过只使用个体偏好和热门度的 baseline。

实验还设置了防泄露边界。用户主题偏好、关联规则、候选视频集合、视频热门度和用户分群统计全部由训练集构建，测试集只用于评估。该设计使推荐方案不能提前看到用户后续行为，评估结果更接近真实推荐系统中的时间顺序场景。

3 数据清洗与特征构建

3.1 用户-视频级交互表

原始数据中同一次曝光可能因多个标签而对应多行记录，如果直接统计会重复计算曝光和互动。项目以 `user_id`、`pid` 和 `exposed_time` 为联合键聚合到用户-视频级粒度。聚合时，观看时长、视频时长、用户属性和主题字段保留首个非空值，点赞、收藏、评论、转发、负反馈和有效观看取逻辑或，标签字段按出现顺序合并为以竖线分隔的标签串。该处理保留了标签信息，又避免了多标签重复行放大主题曝光量。

行为字段被统一转为布尔值，观看时长和视频时长转为数值。有效观看由 $watch_time > 3$ 派生，观看比例按式 1 计算，并截断到 $[0, 1]$ 区间。视频时长缺失或小于等于 0 时，观看比例置为 0。年龄被划分为 ≤ 18 、19-25、26-35、36-45、46-60 和 60+，缺失值进入 `unknown` 分组。

$$WatchRatio = \min \left(\max \left(\frac{watch_time}{duration}, 0 \right), 1 \right) \quad (1)$$

3.2 交互偏好得分

用户对视频主题的偏好不能只依赖是否点击或是否点赞。短视频场景下，观看比例能够反映用户是否停留，点赞、收藏、评论和转发代表更强的正向反馈，负反馈则表示排斥。项目将这些信号合成为交互得分 S ，用于后续用户-主题画像：

$$S = 0.45R + 0.20E + 0.15L + 0.10C + 0.05M + 0.08F - 0.20H \quad (2)$$

式中， R 表示观看比例， E 表示有效观看， L 表示点赞， C 表示收藏， M 表示评论， F 表示转发， H 表示负反馈。对同一用户在同一主题下的交互得分求和，即可得到用户-主题偏好强度。这个分数不是工业推荐模型中的学习参数，而是课程项目中可解释、可复现的偏好刻画方式。

3.3 训练测试切分

项目按用户内部时间顺序进行训练测试切分。对交互数不少于 3 条的用户，前 80% 行为进入训练集，后 20% 行为进入测试集；交互过少的用户只进入训练集，不参与测试评估。最终数据规模见表 2。

表 2: 清洗后数据规模

口径	清洗交互	训练交互	测试交互	用户	视频	主题	规则
数量	129,483	101,690	27,793	6,654	31,496	36	7,658

4 方法设计

4.1 整体流程

项目的处理流程从原始抽样数据开始，经过字段清洗、用户-视频级聚合、训练测试切分、主题统计、用户画像、规则挖掘、推荐排序和离线评估，最终输出结果表与图表。图 1 展示了主要阶段以及训练集与测试集的使用边界。




图 1: 项目整体实验流程

4.2 主题行为统计

主题行为统计按一级主题聚合训练集记录，计算曝光数、用户数、视频数、平均观看时长、平均观看比例、有效观看率、点赞率、收藏率、评论率、转发率和负反馈率。这部分结果用于回答不同主题是否存在观看深度和互动差异，也为后续规则挖掘和推荐解释提供背景。

4.3 关联规则挖掘

关联规则将每条用户-视频交互转化为一个事务。事务项包括主题项、标签项、用户属性项和行为项，例如 `theme=9`、`tag= 搞笑`、`age_group=19-25`、`behavior=like`。本地 Python 流水线采用轻量 Apriori-style 统计方法，计算一阶或二阶前件到行为后件的支持度、置信度和提升度；Spark 脚本则使用 `pyspark.ml.fpm.FPGrowth` 给出分布式环境下的规则挖掘版本。

$$Support(A \Rightarrow B) = \frac{count(A \cup B)}{N} \quad (3)$$

$$Confidence(A \Rightarrow B) = \frac{count(A \cup B)}{count(A)} \quad (4)$$

$$Lift(A \Rightarrow B) = \frac{Confidence(A \Rightarrow B)}{Support(B)} \quad (5)$$

关联规则不被解释为因果关系。本文只把它作为推荐中的统计辅助信号：与正向行为相关且支持数、置信度和提升度足够高的规则进入主题质量或标签匹配特征；与负反馈相关的规则进入风险惩罚特征。

4.4 推荐方案

Baseline 是对照方法，只使用用户历史主题偏好和视频热门度。候选视频来自训练集中出现过、且用户未看过的视频。对用户 u 和候选视频 i ，基础分数定义为：

$$Score_{base}(u, i) = 0.82P(u, t_i) + 0.18Pop(i) \quad (6)$$

其中， $P(u, t_i)$ 是用户对候选视频主题 t_i 的归一化偏好分， $Pop(i)$ 是候选视频在训练集中的归一化热门度。Baseline 的优势是简单和可解释，局限是只利用个体历史与整体热度，无法利用用户分群和标签规则。

Rule-enhanced 在 baseline 基础上进行重排序。它保留个体偏好作为主体，同时引入五类训练集信号：用户分群主题成功率 G 、主题规则质量 Q 、相似主题迁移 Sim 、标签规则匹配 Tag 和负反馈风险 $Risk$ 。最终分数为：

$$Score_{enh}(u, i) = 0.58Score_{base}(u, i) + 0.16G(u, t_i) + 0.11Q(t_i) \quad (7)$$

$$+ 0.08Sim(u, t_i) + 0.09Pop(i) + 0.05Tag(u, i) - 0.07Risk(u, t_i) \quad (8)$$

分群主题成功率来自性别、年龄段和城市等级下的主题反馈统计，并通过全局主题表现平滑。相似主题迁移由用户高偏好主题共现关系估计。标签规则匹配用于捕捉候选视频标签与用户历史正反馈标签的重合。负反馈风险用于降低用户已明确排斥或规则层面风险较高的主题。

5 实验结果与分析

5.1 主题行为差异

高曝光主题的统计结果见表 3。影视和短剧是样本中曝光最多的主题，但其平均观看比例低于搞笑、生活、亲子和明星娱乐。亲子主题的平均观看比例达到 0.5629，有效观看率为 0.7448，说明该主题虽然曝光规模低于影视和短剧，但观看完整度更高。音乐和游戏的点赞率相对更高，表明互动反馈和观看深度不一定同步变化。

表 3: 高曝光主题行为统计

主题	曝光数	平均观看比例	有效观看率	点赞率
影视和短剧	18,469	0.3704	0.7283	0.0177
搞笑	11,623	0.5114	0.7607	0.0206
美食	7,298	0.4290	0.6905	0.0148
生活	6,298	0.5239	0.7191	0.0168
亲子	4,656	0.5629	0.7448	0.0174
游戏	4,653	0.4965	0.7423	0.0258
音乐	4,411	0.3529	0.6629	0.0329
明星娱乐	3,634	0.5167	0.7664	0.0261

图 2 与图 3 从平均观看时长和互动率两个角度展示主题差异。观看时长较长的主题不一定拥有最高点赞率，这说明推荐排序如果只依赖单一行为信号，容易偏向某类反馈而忽略用户对内容的真实停留情况。




图 2：不同主题平均观看时长对比




图 3：高曝光主题互动率对比

5.2 关联规则结果

训练集共挖掘出 7,658 条规则。表 4 列出部分高提升度规则。样例显示，部分标签和用户分组组合与点赞行为具有明显高于全局平均的关系。例如，tag= 一人分饰多角到点赞行为的提升度为 5.2541，表示带有该标签的交互中点赞发生概率相对全局点赞概率更高；age_group=19-25 与若干主题组合也多次出现在高提升度规则中，说明年轻用户在部分主题下存在更强的点赞倾向。

表 4: 关联规则样例

前件	后件	支持数	置信度	提升度
tag= 一人分饰多角	behavior=like	20	0.1070	5.2541
age_group=19-25 & theme=20	behavior=like	49	0.0729	3.5821
tag= 捕娱计划	behavior=like	24	0.0706	3.4677
age_group=19-25 & theme=19	behavior=like	24	0.0694	3.4076
age_group=19-25 & city_level= 二线城市	behavior=like	203	0.0691	3.3955

这些规则的价值不在于替代个体偏好，而在于补充个体偏好。对于历史行为较少的用户，分群规则提供了平滑参考；对于主题偏好相近但标签差异较大的候选视频，标签规则可以提供细粒度区分；对于负反馈风险较高的主题，规则能够阻止纯热门视频进入推荐列表。

5.3 推荐效果

测试集中满足有效观看、点赞、收藏、评论或转发任一条件且没有负反馈的记录被视为正反馈。评估指标包括 HitRate@10、Precision@10、Recall@10 和 ThemeMatch@10。结果见表 5。

表 5: 推荐效果评估

方法	HitRate@10	Precision@10	Recall@10	ThemeMatch@10
Baseline	0.023013	0.002398	0.008712	0.412038
Rule-enhanced	0.026107	0.002649	0.009914	0.423806

相对提升见表 6。Rule-enhanced 在四项指标上都获得提升，其中 HitRate@10 提升 13.44%，Recall@10 提升 13.80%。ThemeMatch@10 的提升幅度较小，但它反映的是推荐主题与测试正反馈主题的一致程度，能够说明增强策略没有仅靠热门视频获得偶然命中，而是在主题层面更贴近用户后续兴趣。

表 6: Rule-enhanced 相对 Baseline 的提升幅度

指标	Baseline	Rule-enhanced	相对提升
HitRate@10	0.023013	0.026107	13.44%
Precision@10	0.002398	0.002649	10.47%
Recall@10	0.008712	0.009914	13.80%
ThemeMatch@10	0.412038	0.423806	2.86%




图 4: Baseline 与 Rule-enhanced 推荐效果对比

指标绝对值不高，主要原因是抽样数据规模有限，测试集中每个用户的正反馈视频较少，候选集合又受到训练集出现视频的限制。在这种约束下，rule-enhanced 仍能稳定超过 baseline，说明规则增强特征没有破坏个体偏好主体，反而在个体历史不足或主题相近时提供了有效补充。

5.4 用户分群偏好

图 5 展示了性别与主题之间的偏好差异。不同用户分组对主题的响应并不一致，这为分群主题成功率进入推荐排序提供了数据依据。分群特征不应被理解为对用户兴趣的固定刻板划分，它在本文中只作为训练集统计信号，用于缓解个体历史稀疏问题。




图 5: 性别-主题偏好热力图

6 大数据工具实现与可复现性

6.1 Python 本地流水线

本地实验由 `scripts/run_local_pipeline.py` 执行。脚本从原始抽样 CSV 读取数据，完成布尔字段清洗、观看比例计算、年龄和价格分组、主题映射、用户-视频级去重、训练测试切分、主题统计、用户画像、规则挖掘、推荐排序、评估和图表输出。所有关键结果都写入 `data_clean/` 与 `output/`，便于报告中的数字回到文件中复核。

`scripts/check_outputs.py` 用于检查关键产物是否存在并打印摘要。当前校验结果显示，清洗交互数、主题数、规则数、推荐条数和评估指标均与报告一致。这个脚本是项目复现链条中的质量门：如果输出文件缺失或为空，报告结论不能被视为可验证。

6.2 Spark 与 Hive 实现

Spark 脚本位于 `spark/theme_preference_spark.py`，实现了分布式版本的主题行为统计和 FP-Growth 规则挖掘。脚本使用 Spark SQL 读取 CSV，派生有效观看和观看比例，按用户、视频和曝光时间聚合记录，再输出主题统计表和规则文件。该版本面向更大规模数据，展示了同一分析逻辑迁移到分布式计算环境的方式。

Hive SQL 位于 `hive/shortvideo_analysis.sql`，包含原始交互表、类别映射表、清洗视图、主题行为汇总表、用户主题偏好表 and 用户分组主题统计表。实际部署时需要根据 HDFS 路径调整 `LOCATION`。Hive 部分的作用是展示离线数仓处理思路，使课程项目不只停留在本地脚本层面。

6.3 仓库产物

项目最终产物分为四类。代码产物包括 Python 本地流水线、Spark 脚本和 Hive SQL；数据产物包括清洗后的交互表、用户画像表和视频目录表；结果产物包括主题统计、用户分组统计、用户主题偏好、规则文件、推荐列表和评估表；展示产物包括可视化图表、README、交接文档和最终 PDF 报告。该结构使报告、代码和结果之间保持可追踪关系。

7 讨论与改进方向

实验结果表明，主题级规则和群体偏好可以改善推荐排序，但当前方案仍然是一个面向课程项目的可解释基线。其局限主要体现在三个方面。数据方面，抽样时间窗口较短，无法充分观察用户兴趣变化。候选方面，推荐视频来自训练集中出现过的内容，未覆盖新视频冷启动。模型方面，rule-enhanced 的权重由人工设定，虽然便于解释，但没有通过学习排序或交叉验证自动优化。

后续可以沿三条路径改进。数据层面，可以使用更长时间范围和更完整的交互记录，并保留更多内容侧特征。方法层面，可以引入矩阵分解、双塔召回或学习排序模型，将本文构造的主题规则特征作为可解释侧特征。评估层面，可以增加按用户历史长度、主题热度和城市等级划分的分层评估，判断规则增强对冷启动用户和长尾主题是否更有效。

8 小组分工

本项目由四名成员共同完成，分工见表 7。成员顺序按课程提交要求排列。

表 7: 小组成员分工

成员	主要任务
梁珂	负责数据清洗、字段标准化、用户-视频级交互表构建、Hive 表结构设计和离线统计 SQL 编写。
方家烨	负责项目选题、研究问题定义、数据集阅读、整体技术路线设计，以及开题与最终报告统筹。
李俊婕	负责主题偏好分析、用户分群统计、关联规则挖掘、可视化图表整理和实验结果分析。
刘翔	负责推荐策略设计、baseline 与 rule-enhanced 对比实验、评估指标计算、Spark 脚本实现和 GitHub 项目整理。

9 结论

本文基于 Tsinghua ShortVideo Dataset 的抽样数据，完成了短视频主题偏好分析与推荐策略优化实验。项目将原始多标签曝光记录清洗为 129,483 条用户-视频级交互，构建了用户主题偏好画像，挖掘出 7,658 条主题、标签、用户属性与行为之间的关联规则，并在严格时间切分下比较 baseline 与 rule-enhanced 两种推荐方法。实验结果显示，rule-enhanced 在四项离线指标上均超过 baseline，说明训练集中的主题规律、分群反馈和标签规则能够对个体历史偏好形成补充。

从课程实践角度看，项目覆盖了大数据处理的主要环节：数据读取、字段清洗、结构化聚合、规则挖掘、推荐排序、离线评估、图表展示和报告输出。Python 流水线保证本地复现，Spark 与 Hive 文件展示了面向大规模数据处理的实现思路，最终仓库保留了代码、清洗结果、统计表、规则、推荐列表、图表和报告，能够支撑课程项目提交与后续扩展。

项目仓库

<https://github.com/c0ffee-milk/short-video-theme-recommendation>